

МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ  
КОММУНИКАЦИЙ РОССИЙСКОЙ ФЕДЕРАЦИИ  
Ордена Трудового Красного Знамени федеральное государственное  
бюджетное образовательное учреждение высшего образования  
**«Московский Технический Университет Связи И Информатики  
(MTUCI)»**

Кафедра «Математическая кибернетика и информационные технологии»

# **Лабораторная Работа 2**

по дисциплине

**«Машинное обучение»**

Выполнил: студент 3 курса гр. БВТ2201  
Ньяти Каелиле

Москва 2025 г

## Содержание

1. Задание
2. Ход работы
3. Вывод

## 1. Задание

Обучить MNIST. MNIST это набор картинок размер которых 1x28x28. Берите датасет в котором пиксель может быть вещественным числом от 0 до 1. Это задача классификации, на каждой картинке написана цифра, и нужно предктнуть что это за цифра.

## 2. Ход работы

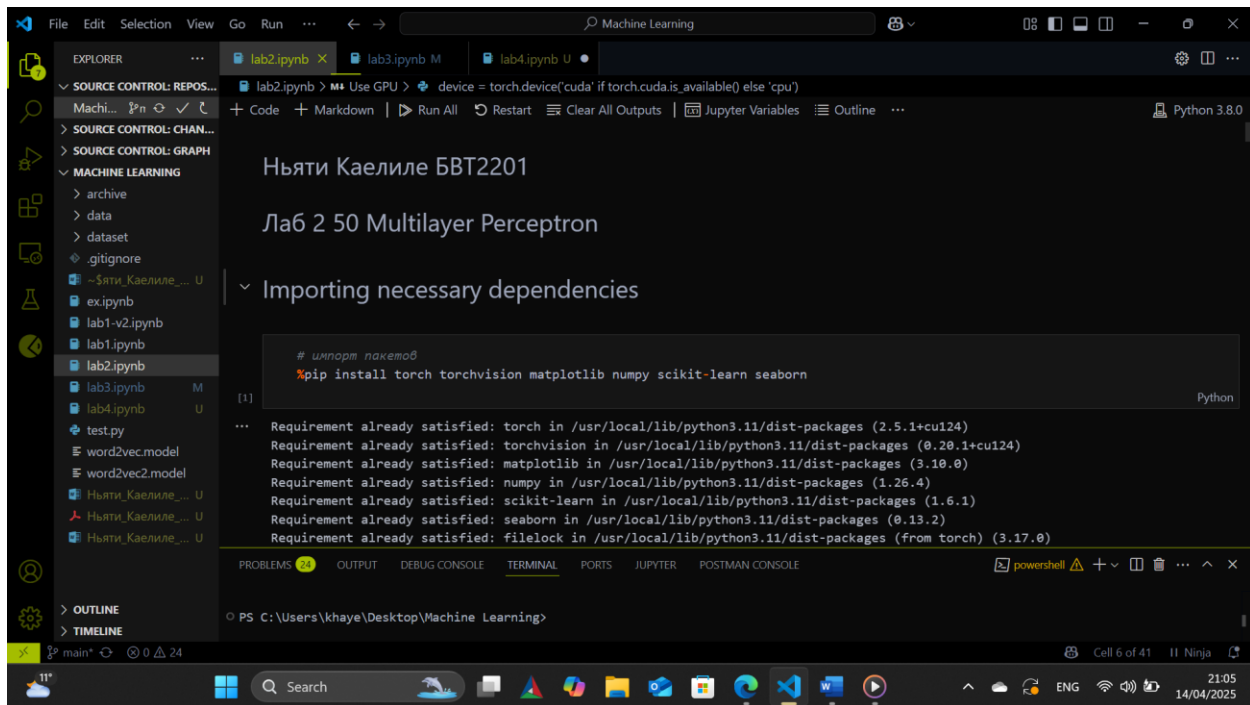
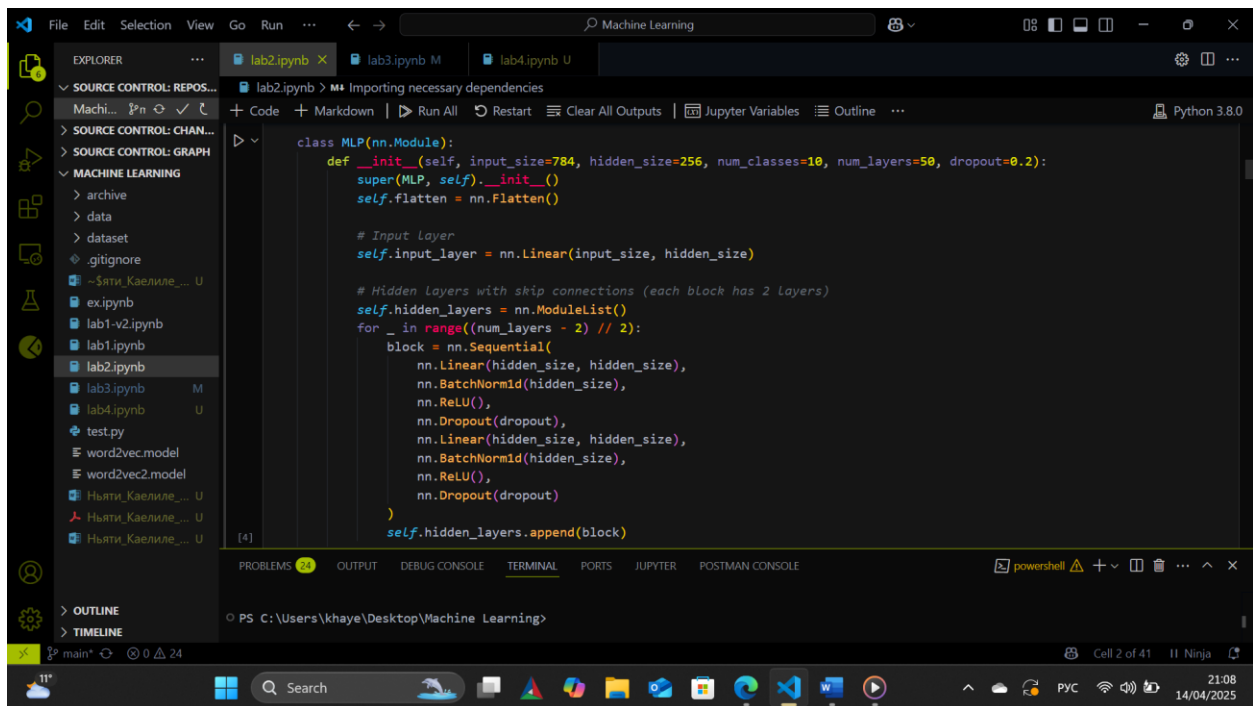
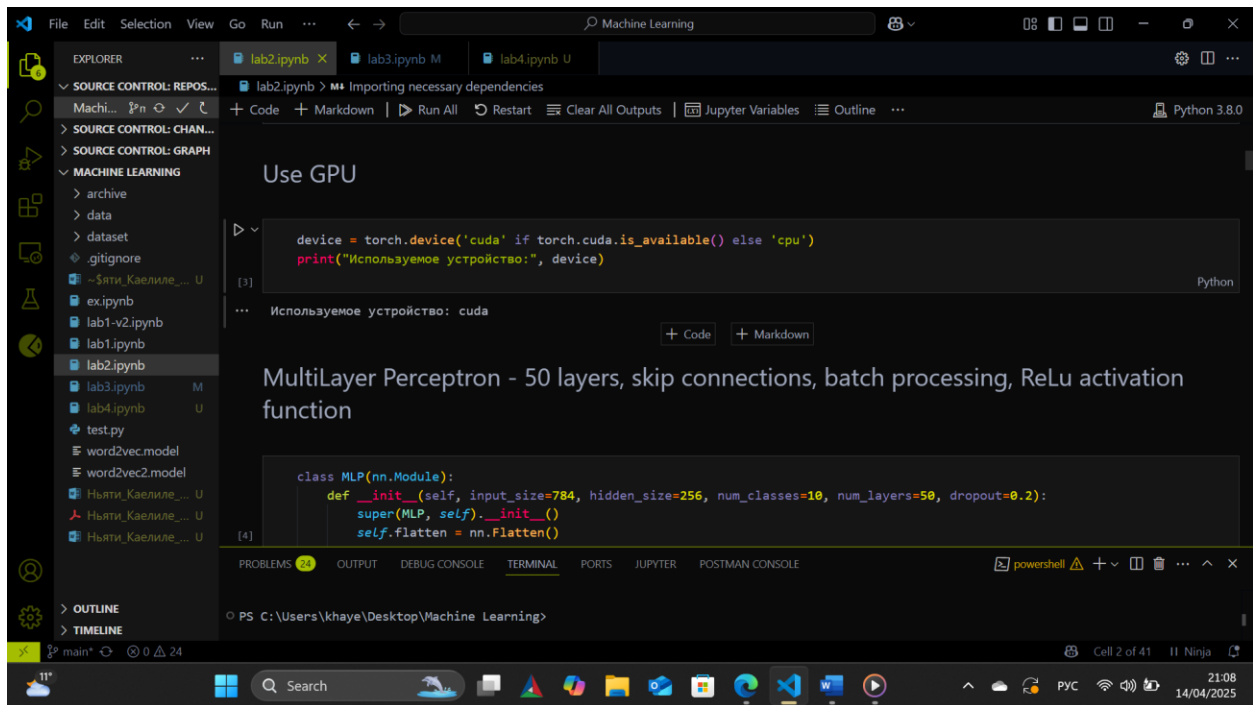


Рис 1. Библиотеки



```
import torch.nn as nn
import torch.nn.functional as F

class MLP(nn.Module):
    def __init__(self, hidden_size, num_classes):
        super(MLP, self).__init__()
        self.hidden_layers = nn.ModuleList()
        self.output_layer = nn.Linear(hidden_size, num_classes)

        # Output Layer
        self.output_layer = nn.Linear(hidden_size, num_classes)

    def forward(self, x):
        x = self.flatten(x)
        x = self.input_layer(x)

        for block in self.hidden_layers:
            x = x + block(x) # Skip connection every 2 Layers

        x = self.output_layer(x)
        return x # No softmax (handled in Loss function)

    # Instantiate and print the model
    model = MLP()
    print(model)

    # Move the model to CUDA
    model = MLP().to(device)
```

```
class MLP(nn.Module):
    def __init__(self):
        super(MLP, self).__init__()
        (flatten): Flatten(start_dim=1, end_dim=-1)
        (input_layer): Linear(in_features=784, out_features=256, bias=True)
        (hidden_layers): ModuleList(
          (0-23): 24 x Sequential(
            (0): Linear(in_features=256, out_features=256, bias=True)
            (1): BatchNorm1d(256, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
            (2): ReLU()
            (3): Dropout(p=0.2, inplace=False)
            (4): Linear(in_features=256, out_features=256, bias=True)
            (5): BatchNorm1d(256, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
            (6): ReLU()
            (7): Dropout(p=0.2, inplace=False)
          )
        )
        (output_layer): Linear(in_features=256, out_features=10, bias=True)
    )
```

Рис 2. MLP

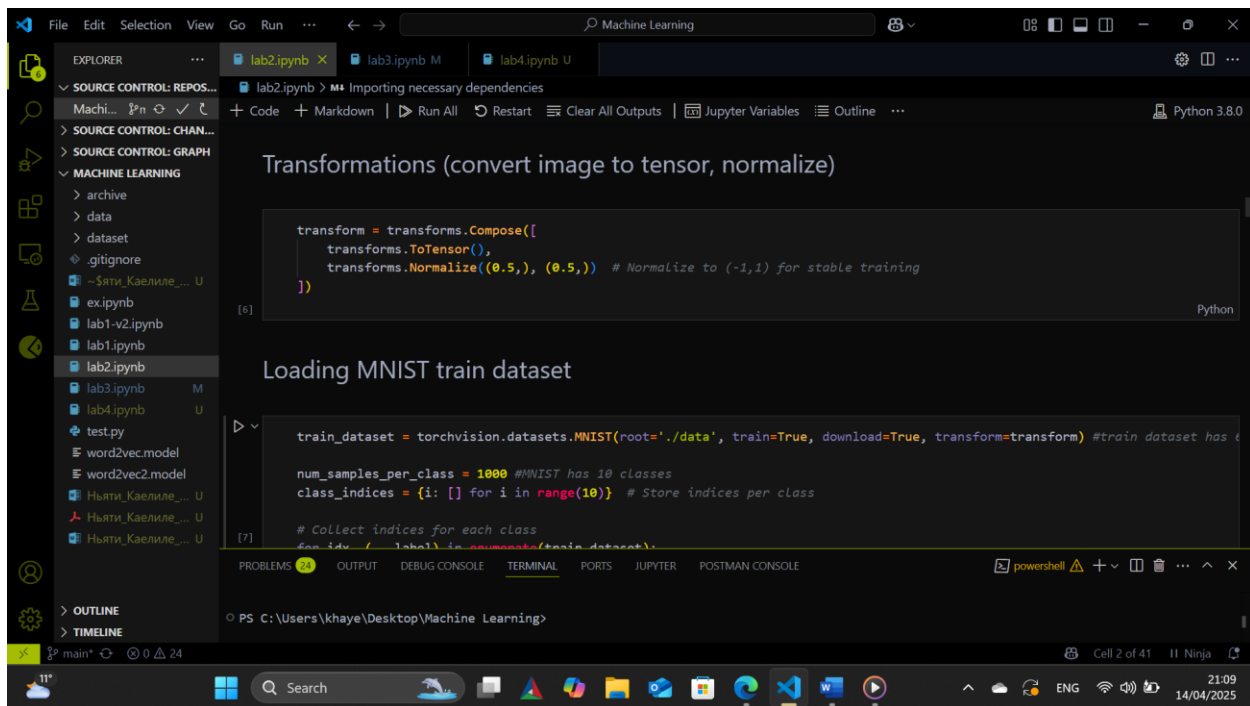
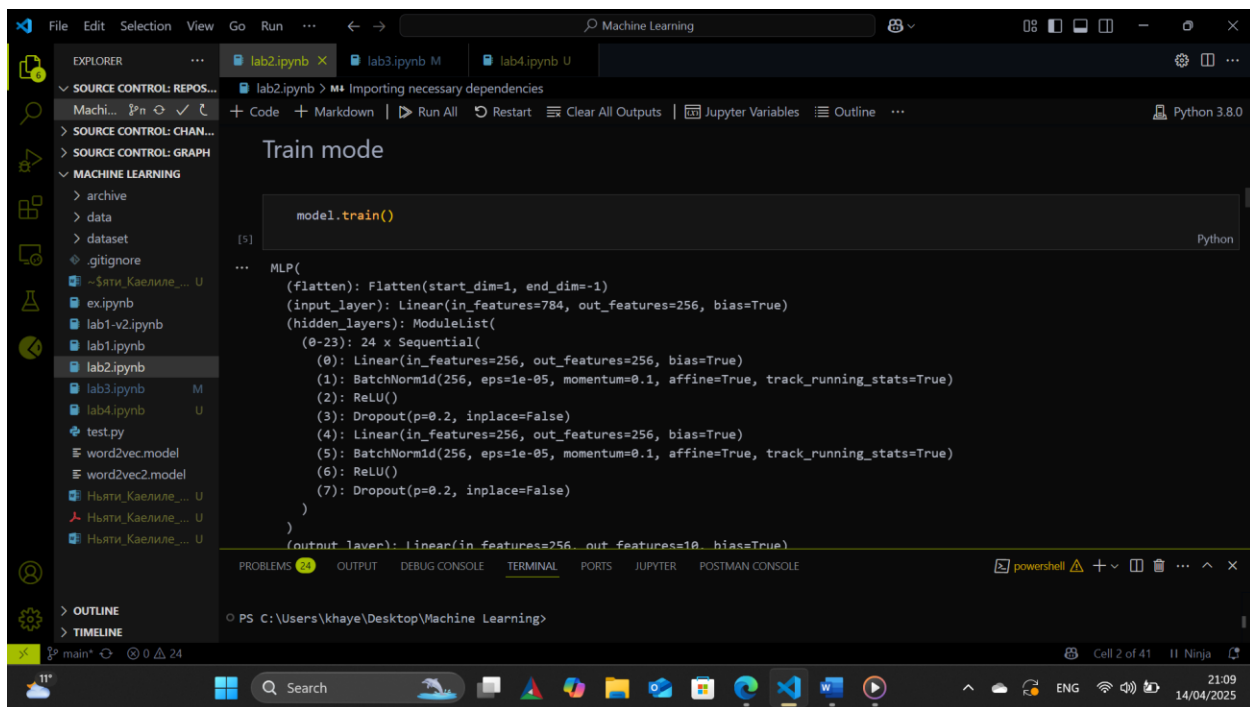


Рис 3. Трансформаций

```
train_dataset = torchvision.datasets.MNIST(root='./data', train=True, download=True, transform=transform) #train dataset has t

num_samples_per_class = 1000 #MNIST has 10 classes
class_indices = {i: [] for i in range(10)} # Store indices per class

# Collect indices for each class
for idx, (_, label) in enumerate(train_dataset):
    if len(class_indices[label]) < num_samples_per_class:
        class_indices[label].append(idx)

# Flatten the List of selected indices
selected_indices = [idx for indices in class_indices.values() for idx in indices]
train_subset = torch.utils.data.Subset(train_dataset, selected_indices)

train_loader = torch.utils.data.DataLoader(train_subset, batch_size=16, shuffle=True)

[7] #print(len(train_dataset)) # Total number of images in the dataset
```

```
test_dataset = torchvision.datasets.MNIST(root='./data', train=False, download=True, transform=transform)

num_samples_per_class = 200 #MNIST has 10 classes
class_indices = {i: [] for i in range(10)} # Store indices per class

# Collect indices for each class
for idx, (_, label) in enumerate(train_dataset):
    if len(class_indices[label]) < num_samples_per_class:
        class_indices[label].append(idx)

# Flatten the List of selected indices
selected_indices = [idx for indices in class_indices.values() for idx in indices]
test_subset = torch.utils.data.Subset(test_dataset, selected_indices)

test_loader = torch.utils.data.DataLoader(test_subset, batch_size=16, shuffle=True)

[8]
```

Рис 4. Дата лоудер

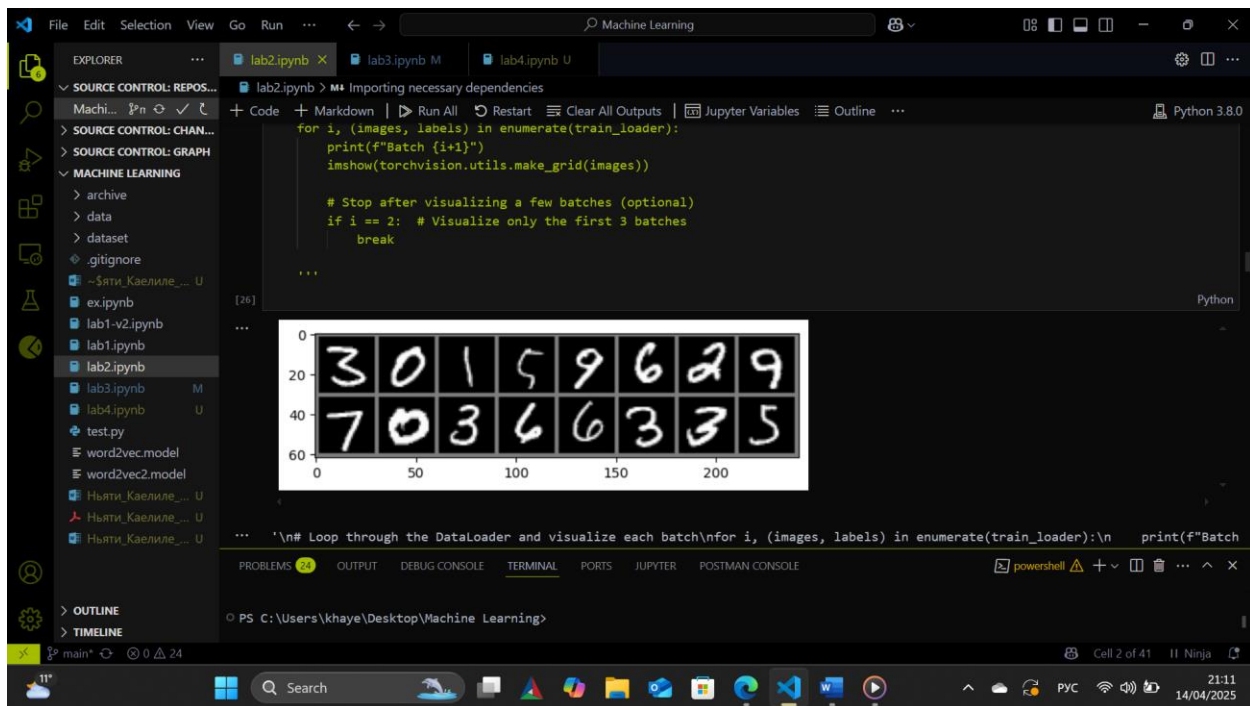
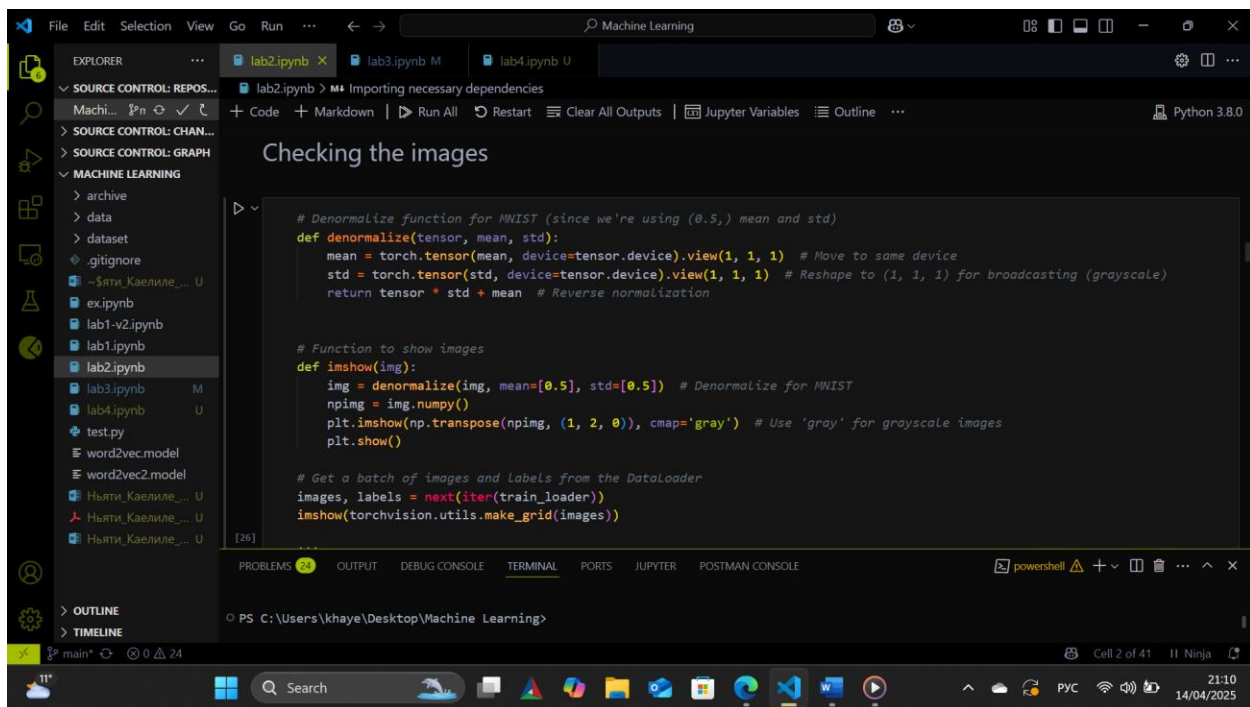


Рис 5. Изображение



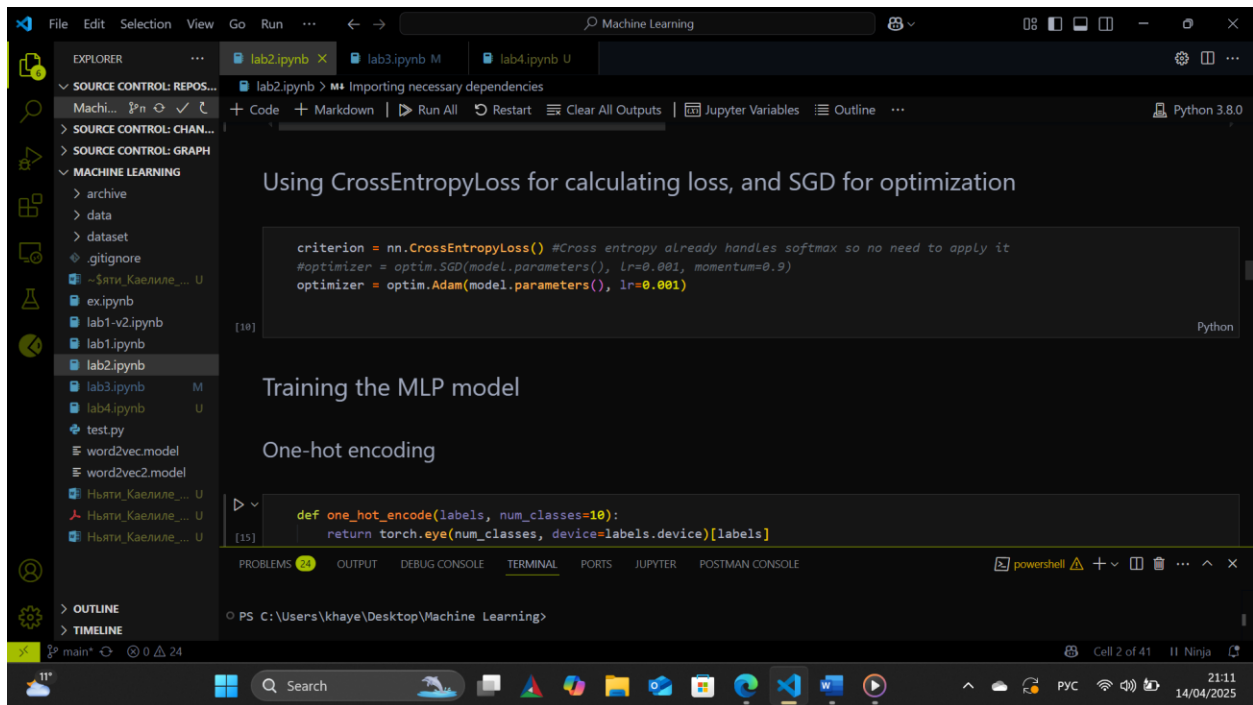


Рис 6. Loss function

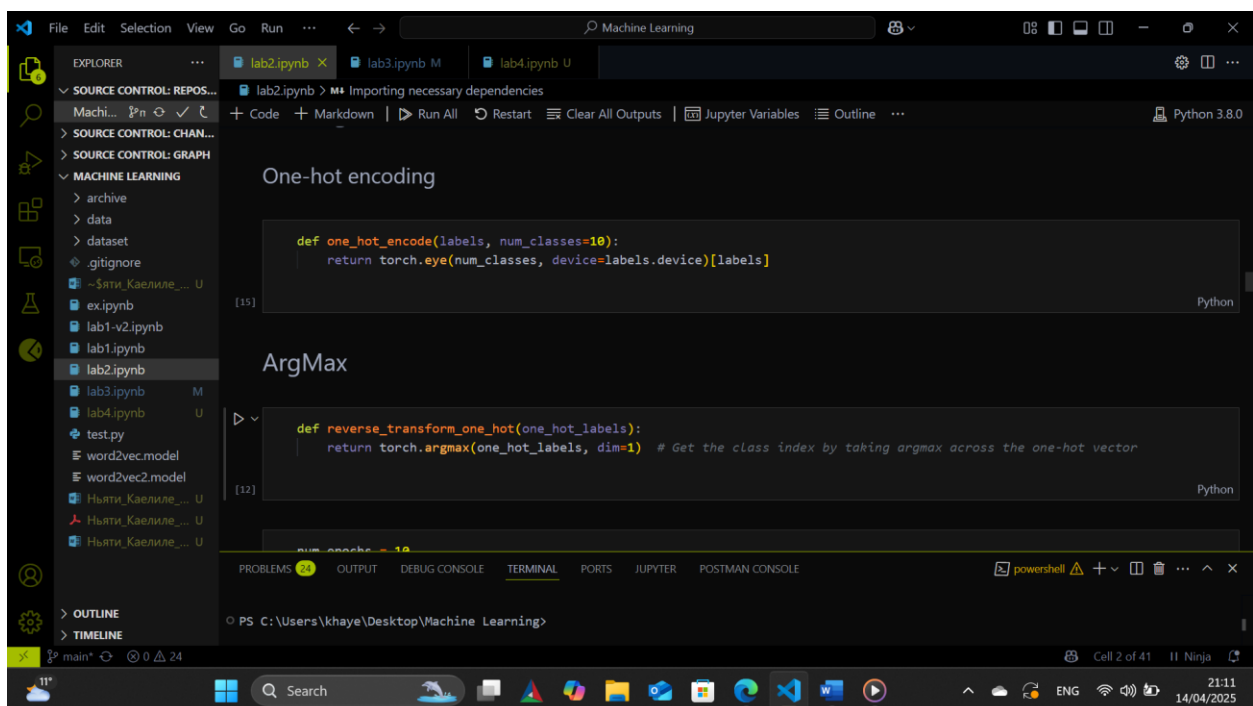


Рис 7. One Hot Encoding, ArgMax

```
num_epochs = 10
loss_history = [] # Store loss for visualization

true_labels_OHE = []
predicted_labels_OHE = []

for epoch in range(num_epochs):
    running_loss = 0.0
    progress_bar = tqdm(train_loader, desc=f"Epoch {epoch+1}/{num_epochs}", leave=False) # Progress bar

    for inputs, labels in train_loader:
        inputs, labels = inputs.to(device), labels.to(device)

        # One-hot encode the labels
        one_hot_labels = one_hot_encode(labels).to(device)

        optimizer.zero_grad()

        outputs = model(inputs)
```

```
softmax = nn.Softmax(dim=1)
probabilities = softmax(outputs)

# Get predicted class indices
_, preds = torch.max(outputs, 1)

# Convert predictions to one-hot (optional, for comparison)
one_hot_preds = one_hot_encode(preds)

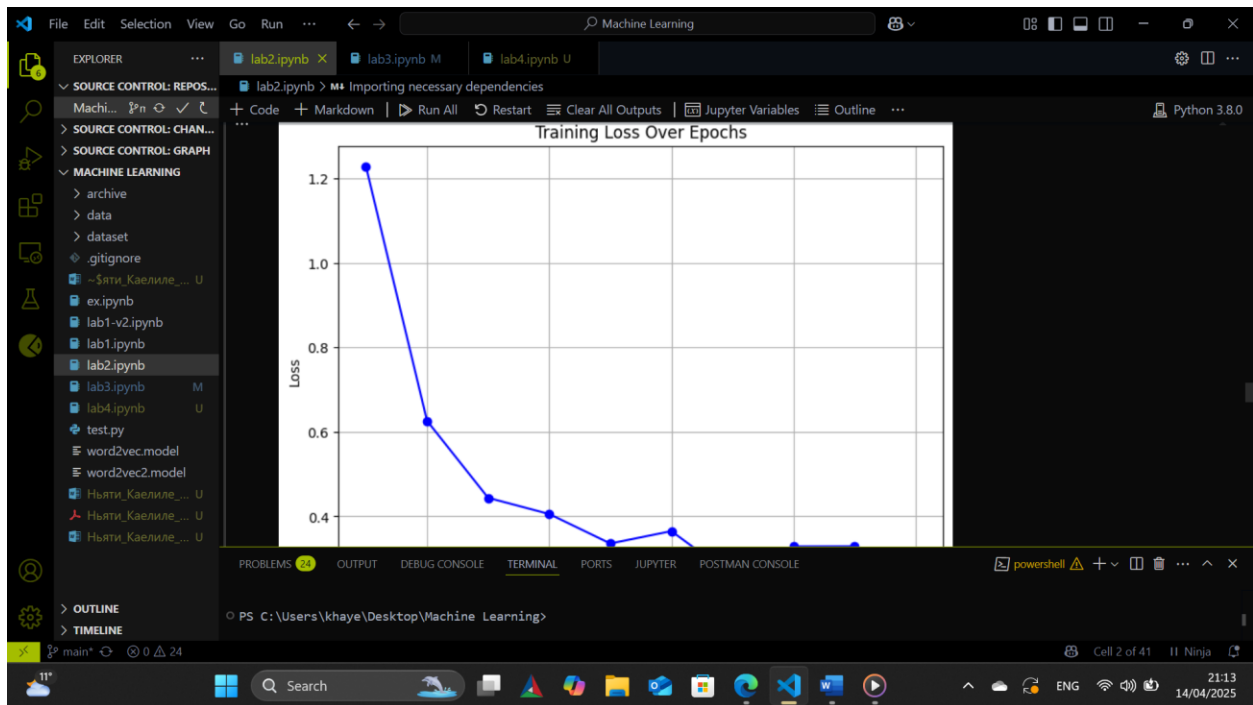
# Reverse transformation from one-hot to class index
predicted_class_indices = reverse_transform_one_hot(one_hot_preds)

# Store true and predicted labels
true_labels_OHE.extend(labels.cpu().numpy()) # Convert tensor to List
predicted_labels_OHE.extend(predicted_class_indices.cpu().numpy()) # Convert tensor to List

optimizer.step()

running_loss += loss.item() * inputs.size(0)
progress_bar.set_postfix(loss=loss.item()) # Show current Loss
```





Python 3.8.0

```
plt.ylabel("True Label")
plt.show()
```

	precision	recall	f1-score	support
zero	0.90	0.99	0.95	180
one	0.96	0.99	0.97	232
two	0.94	0.87	0.90	216
three	0.99	0.75	0.85	202
four	0.97	0.67	0.79	218
five	0.97	0.80	0.88	179
six	0.89	0.95	0.92	186
seven	0.84	0.87	0.86	204
eight	0.87	0.88	0.88	191
nine	0.61	0.99	0.76	192
accuracy			0.87	2000
macro avg	0.89	0.88	0.87	2000
weighted avg	0.90	0.87	0.88	2000

PS C:\Users\khaye\Desktop\Machine Learning>

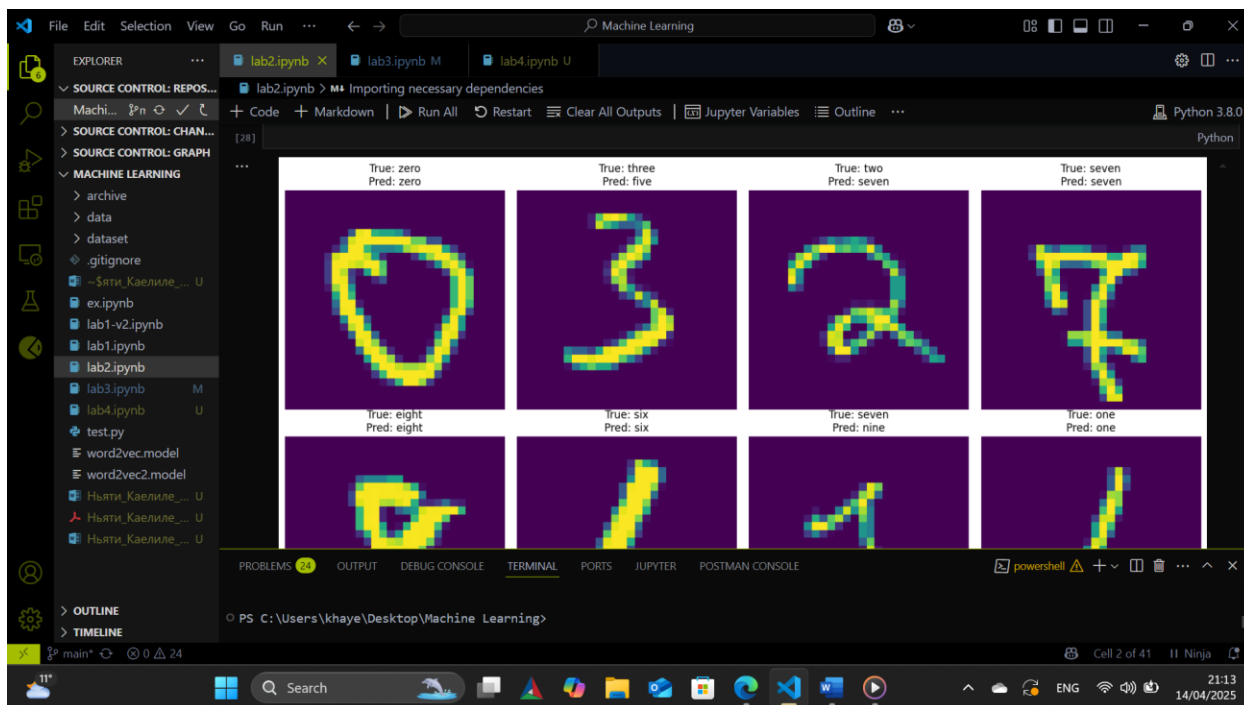


Рис 8. Результаты

### 3. Выводы

В ходе выполнения задания был использован датасет MNIST, содержащий изображения рукописных цифр, для обучения и тестирования алгоритмов классификации. Реализованный подход продемонстрировал способность эффективно распознавать цифры благодаря хорошо структурированным данным и применению современных методов машинного обучения. Результаты подтверждают пригодность выбранных алгоритмов для решения задач распознавания образов и подчеркивают важность качественных датасетов в процессе обучения моделей.