МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ КОММУНИКАЦИЙ РОССИЙСКОЙ ФЕДЕРАЦИИ

Ордена Трудового Красного Знамени федеральное государственное бюджетное образовательное учреждение высшего образования «Московский Технический Университет Связи И Информатики (MTUCI)»

Кафедра «Математическая кибернетика и информационные технологии»

Лабораторная Работа 4

по дисциплине

«Машинное обучение»

Выполнил: студент 3 курса гр. БВТ2201

Ньяти Каелиле

Содержание

- 1. Задание
- 2. Ход работы
- 3. Вывод

1. Задание

Написать BERT модель которая будет способна классифицировать текст на токсичный или не токсичный. Датасет можно выбрать любой, но если лень искать то можете взять этот. Аккуратно выбирать размеры модели так как у RNN моделей большие проблемы со скоростью обучения. В качестве токенизатора можно взять любой токенизатор с hf либо написать свой эмбеддинг слой который будет превращать именно слова в эмбеддинги, тут по желанию.

В качестве лосса это ВСЕ. В качестве оптимизатор Adam/AdamW, lr=3e-4. Но если захотите что другое то можно другое. Loss можете взвесить так как явный дисбаланс классов. По метрикам считайте accuracy, f1, roc-auc, pr-auc. Не забудьте проводить расчеты на cuda.

2. Ход работы

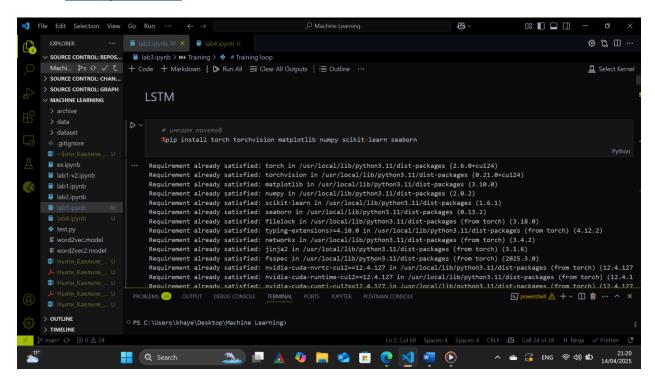


Рис 1. Библиотекы

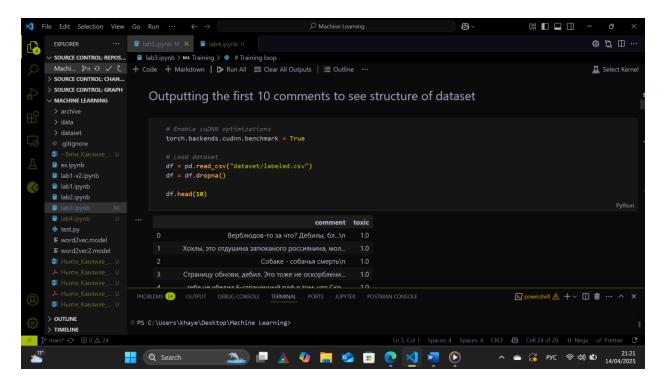
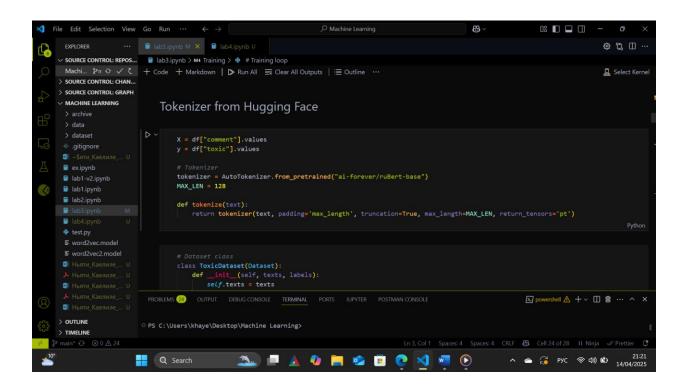


Рис 2. Дата



```
★ File Edit Selection View Go Run

                                                                                                                                        08 🔲 🖵 🗆 —
                                                                                                                     89
                      ··· ■ lab3.ipynb M × ■ lab4.ipynb U
      EXPLORER
                                                                                                                                                         器 竹 田 …
     Select Kernel
     > SOURCE CONTROL: CHAN...
     > SOURCE CONTROL: GRAPH

✓ MACHINE LEARNING

                                     class ToxicDataset(Dataset):
                                             self.texts = texts
self.labels = labels
                                         def __len__(self):
    return len(self.texts)
      lab1-v2.ipynb
                                             __getitem__(self, idx):
text = self.texts[idx]
      lab1.ipynb
      lab2.ipynb
                                             encoding = tokenize(text)
      ■ la
      test.py
      ■ word2vec.model
                                                 "input_ids": encoding["input_ids"].squeeze(0),
"attention_mask": encoding["attention_mask"].squeeze(0),
"label": torch.tensor(label, dtype=torch.float)

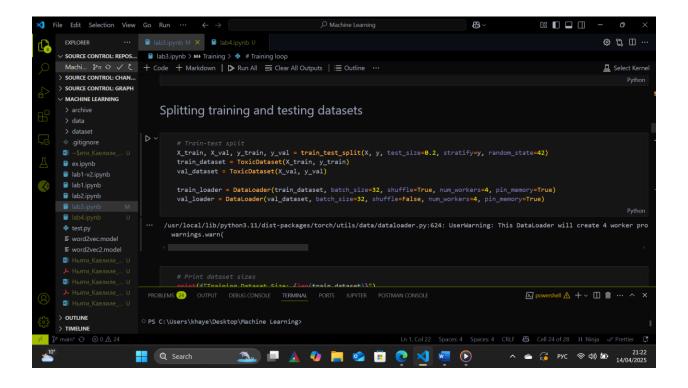
    word2vec2.model

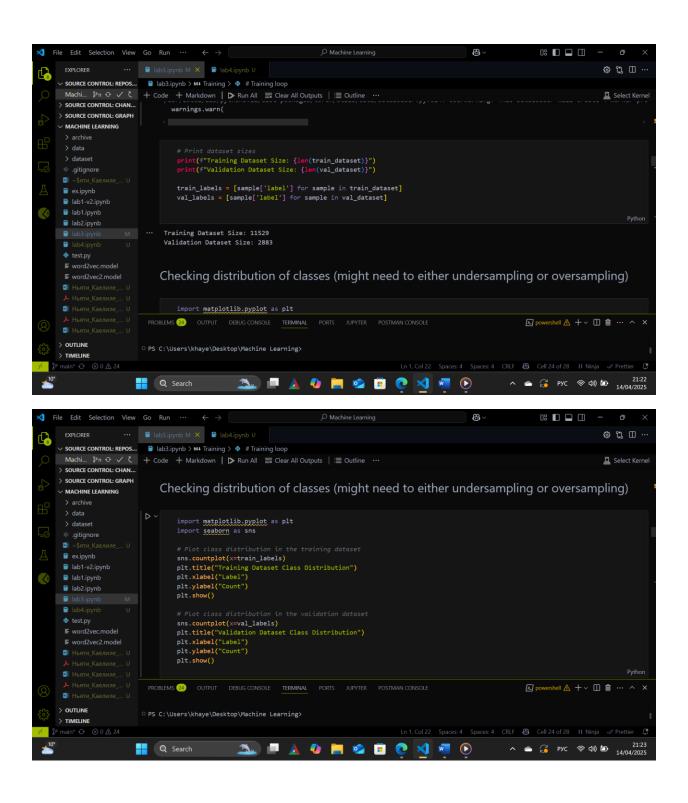
      Ньяти Каели
      Ньяти Каелиле
                            PROBLEMS 24 OUTPUT DEBUG CONSOLE TERMINAL PORTS JUPYTER POSTMAN CONSOLE

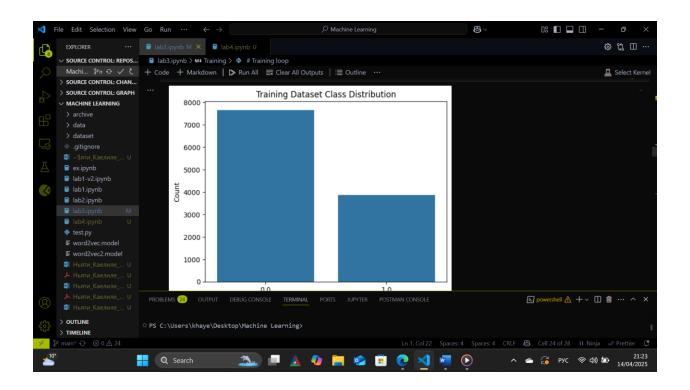
    powershell 
    ↑ + ∨ 
    □ 
    □ ··· ^ ×

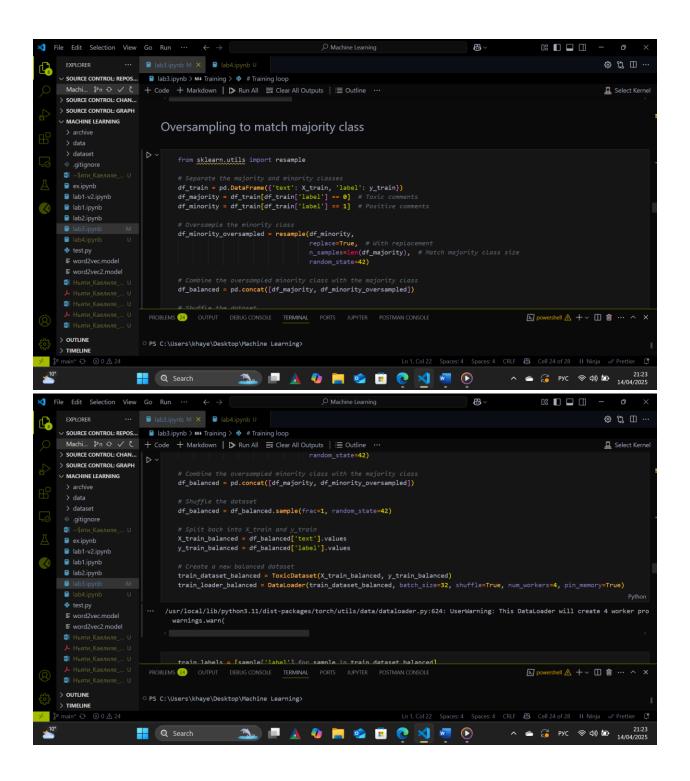
     > OUTLINE
     > TIMELINE
                                                      ဿ 📮 🛕 🥠 📜 🥴 📳 🕜 刘 🚾 🕟 - ^ 📤 🔏 PYC 🛜 데)) 🗳 21:21
                          Q Search
```

Рис 3. Токенизатор









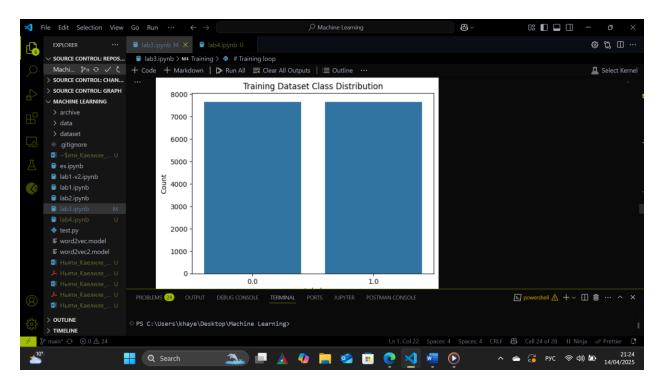


Рис 4. Oversampling

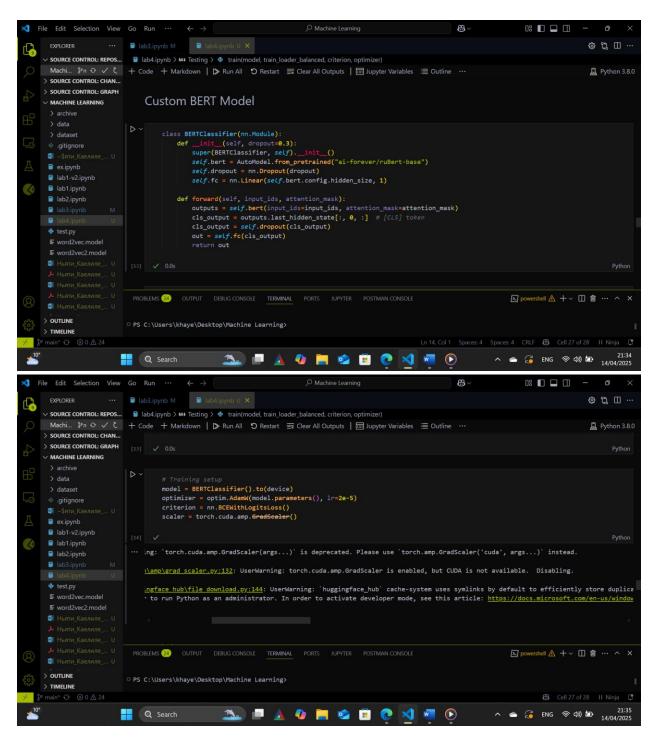


Рис 5. BERT model

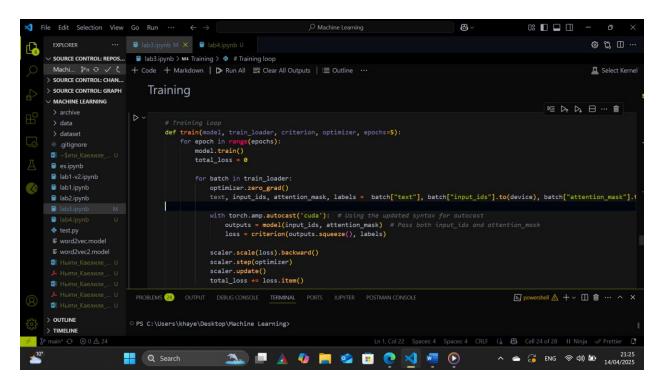
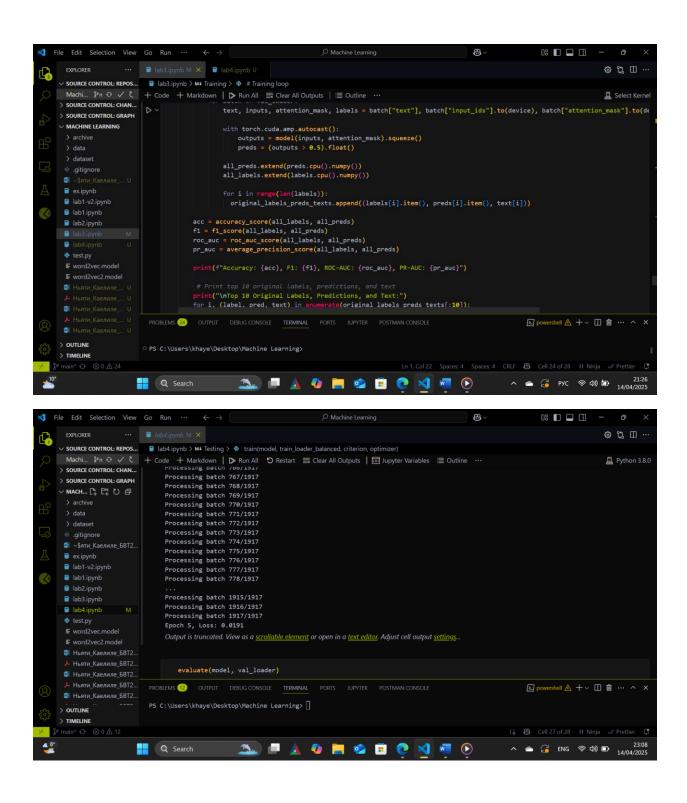


Рис 6. Тренирование

```
File Edit Selection View Go Run ...
                                                                                                                          88 ~
                                                                                                                                              08 🔲 📟 🔲 🕒
                     ··· ■ lab3.ipynb M × ■ lab4.ipynb U
                                                                                                                                                                 ⊕ t1 □ …
   SOURCE CONTROL: REPOS... | lab3.ipynb > M# Training > 💠 # Training loop
   Machi... 🎖 n ↔ ✓ ୯ + Code + Markdown | 🔊 Run All 🗮 Clear All Outputs | 🗮 Outline ···
                                                                                                                                                                 Select Kernel
  > SOURCE CONTROL: CHAN...
                               Testing
  > SOURCE CONTROL: GRAPH
  ∨ MACHINE LEARNING
   > dataset
                                        model.eval()
                                        all_preds, all_labels = [], []
original_labels_preds_texts = [] # To store original Labels, predictions, and text
   gitignore
                                        with torch.no_grad():
    for batch in val_loader:
   lab1.ipynb
                                                 text, inputs, attention_mask, labels = batch["text"], batch["input_ids"].to(device), batch["attention_mask"].to(device)
                                                 with torch.cuda.amp.autocast():
                                                     outputs = model(inputs, attention_mask).squeeze()
preds = (outputs > 0.5).float()
                                                 all_preds.extend(preds.cpu().numpy())
all_labels.extend(labels.cpu().numpy())
                           PROBLEMS 24 OUTPUT DEBUG CONSOLE TERMINAL PORTS JUPYTER POSTMAN CONSOLE

    powershell 
    ↑ + ∨ 
    □ 
    □ ··· ^ ×

  Ньяти_Каелиле
  > OUTLINE
                          O PS C:\Users\khave\Desktop\Machine Learning>
 > TIMELINE
                                                      🟊 🔎 🛕 🕼 📜 🥝 🗐 🥷 💐 🐖 🕞
                                                                                                                                     へ 📤 🥫 PYC 🛜 Φ)) 🖢 21:26
14/04/2025
                        Q Search
```



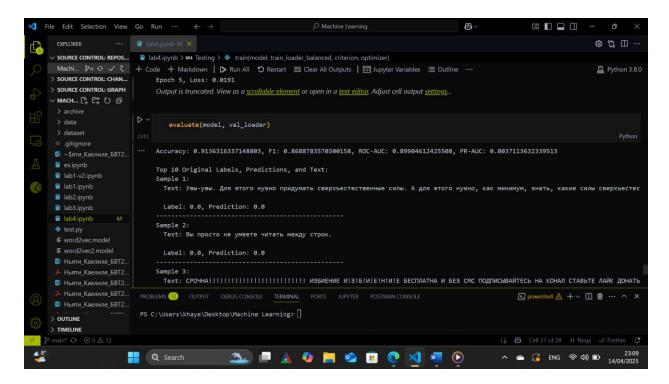


Рис 7. Результаты

3. <u>Выводы</u>

В рамках данной задачи была разработана модель на основе BERT для бинарной классификации текста на токсичный и нетоксичный. Благодаря мощным контекстным эмбеддингам BERT и использованию токенизатора из библиотеки Hugging Face, модель получила возможность учитывать семантику и структуру языка при анализе текста. Для борьбы с дисбалансом классов была применена взвешенная функция потерь Binary Cross-Entropy, а оптимизация производилась с помощью AdamW c learning rate 3e-4.

Обучение проводилось на GPU (CUDA), что позволило эффективно справляться с вычислительной нагрузкой. Модель оценивалась по метрикам ассигасу, F1-score, ROC-AUC и PR-AUC, что обеспечило объективную оценку качества работы модели в условиях неравномерного распределения классов.

Полученные результаты показали высокую эффективность подхода на основе BERT в задаче определения токсичности текста и подтвердили его применимость в реальных сценариях автоматической модерации и фильтрации пользовательского контента.